

BEER XP

MOTOR DE INFERENCIA ,
INFERENCIA CAUSAL

del Mazo Federico
Dvorkin, Camila
Faretta Yanina
Mac Gaul, Pedro
Rombolá, Juan Pablo



AGENDA

01

INTRODUCCIÓN

02

**MOTOR DE
INFERENCIA**

03


**INFERENCIA
CAUSAL**

04

CONCLUSIONES

01

INTRODUCCIÓN



ALGUNOS DATOS INTERESANTES DE LA CERVEZA

La cerveza se elaboraba ya en Mesopotamia alrededor del año 4000 a.C.

El primer viernes de agosto de cada año se celebra el Día Internacional de la Cerveza

La cerveza es la tercera bebida más consumida en el mundo, después del agua y el té.

Se cree que constructores de las pirámides egipcias recibían cerveza como compensación diaria.

En Austria, existe una piscina con 42,000 litros de cerveza que no tiene nada que envidiar al spa de cerveza argentino.

La cenosillicafobia es el miedo irracional a un vaso vacío y se suele asociar a la cerveza

TRABAJO PREVIO

Definí las características de la cerveza para conocer más sobre su composición y preparación

Gravedad Original ?

Muy poco

Gravedad Final ?

Muy poco

Color ?



Amargura ?



Graduación Alcohólica ?



OBTENER CERVEZA

Color ?

Clara

Cuerpo ?

Ligero

Malta ?

Pálida

ABV ?

IBU ?

Bajo
Maridajes ?

Sin amargor

Salado

Torta

Carnes rojas

Carnes blancas


Quesos

Sola

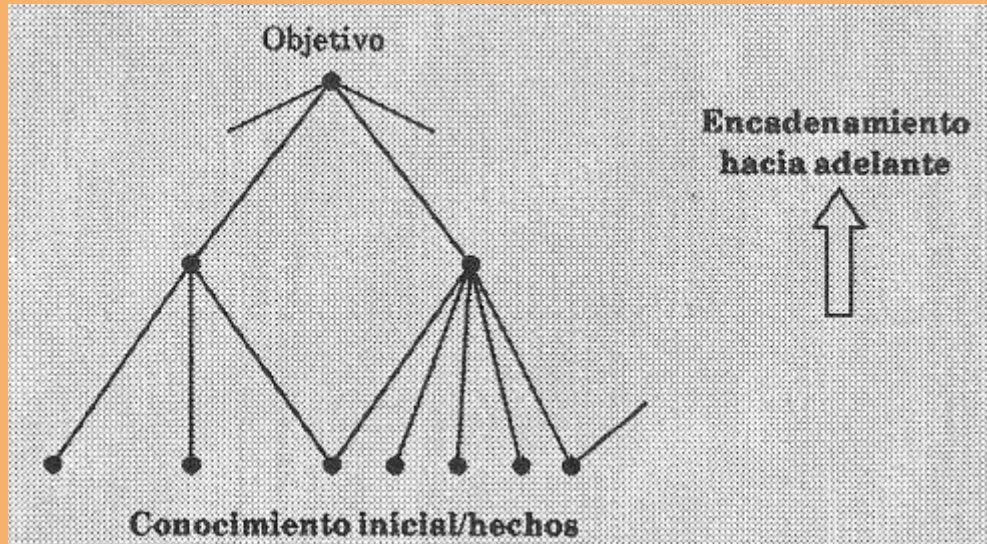
Buscar Cerveza

02

MOTOR DE INFERENCIA



ELECCIÓN DE MECANISMO DE INFERENCIA

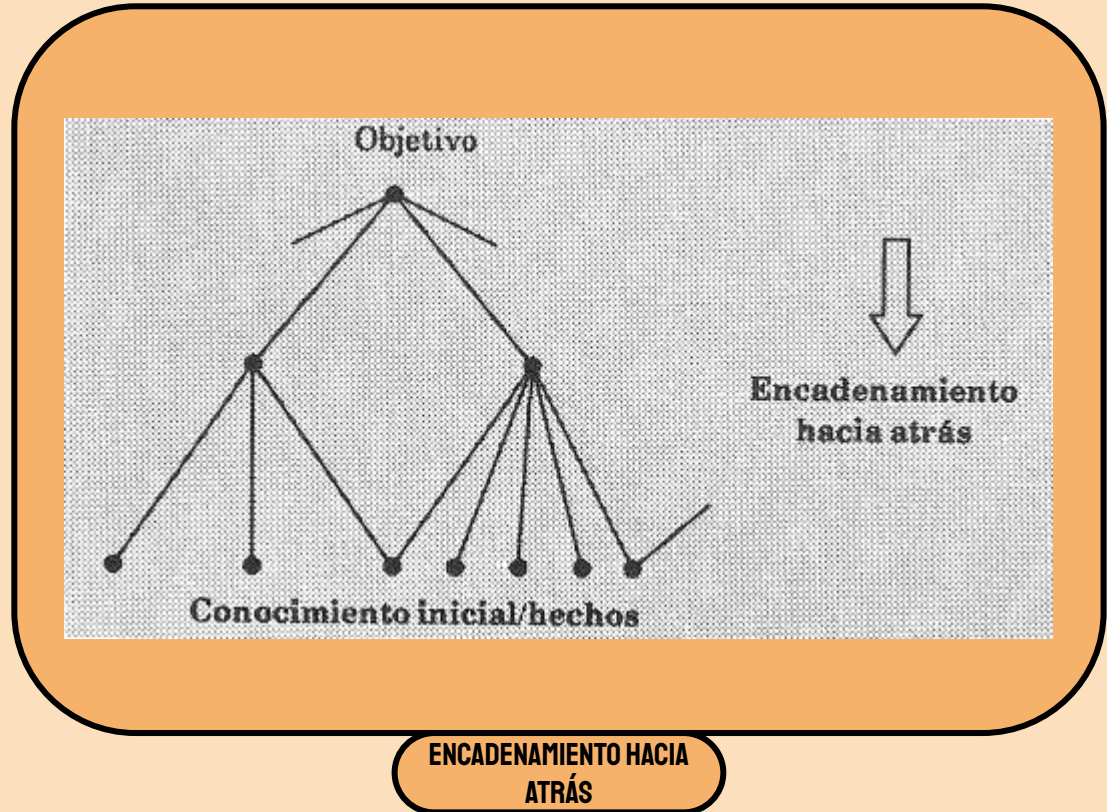


ENCADENAMIENTO HACIA
ADELANTE

- ✓ intuitivo en problemas con información inicial
- ✓ útil para reglas en función de los hechos iniciales
- ✗ lento si hay muchas reglas
- ✗ no es óptimo para soluciones específicas

ELECCIÓN DE MECANISMO DE INFERENCIA

- ✓ eficiente cuando se tiene un objetivo concreto en mente
- ✓ rápido en situaciones con muchas reglas
- ✗ no es intuitivo
- ✗ requiere más interacciones con el usuario



MOTOR DE INFERENCIA

```
class ForwardChainingEngine {
  _countEqualConditionsMatched(conditions) {
    let count = 0;
    conditions
      .filter((c) => !c.any)
      .forEach((condition) => {
        if (this.facts[condition.key] === condition.value) {
          count++;
        }
      });
    return count;
  }

  _countAnyConditionsMatched(conditions) {
    let count = 0;
    conditions
      .filter((c) => c.any)
      .map((c) => c.any)
      .forEach((condition) => {
        const values = this.facts[condition[0].key];
        const conditionvalues = condition.map((c) => c.value);
        if (values && values.some((v) => conditionvalues.includes(v))) {
          count++;
        }
      });
    return count;
  }

  run(initialFacts) {
    this.facts = { ...initialFacts };
    return this._applicableRules(initialFacts);
  }
}
```


Solución: encadenamiento hacia adelante, porque partimos de información inicial proporcionada por el usuario



DEMO!

03

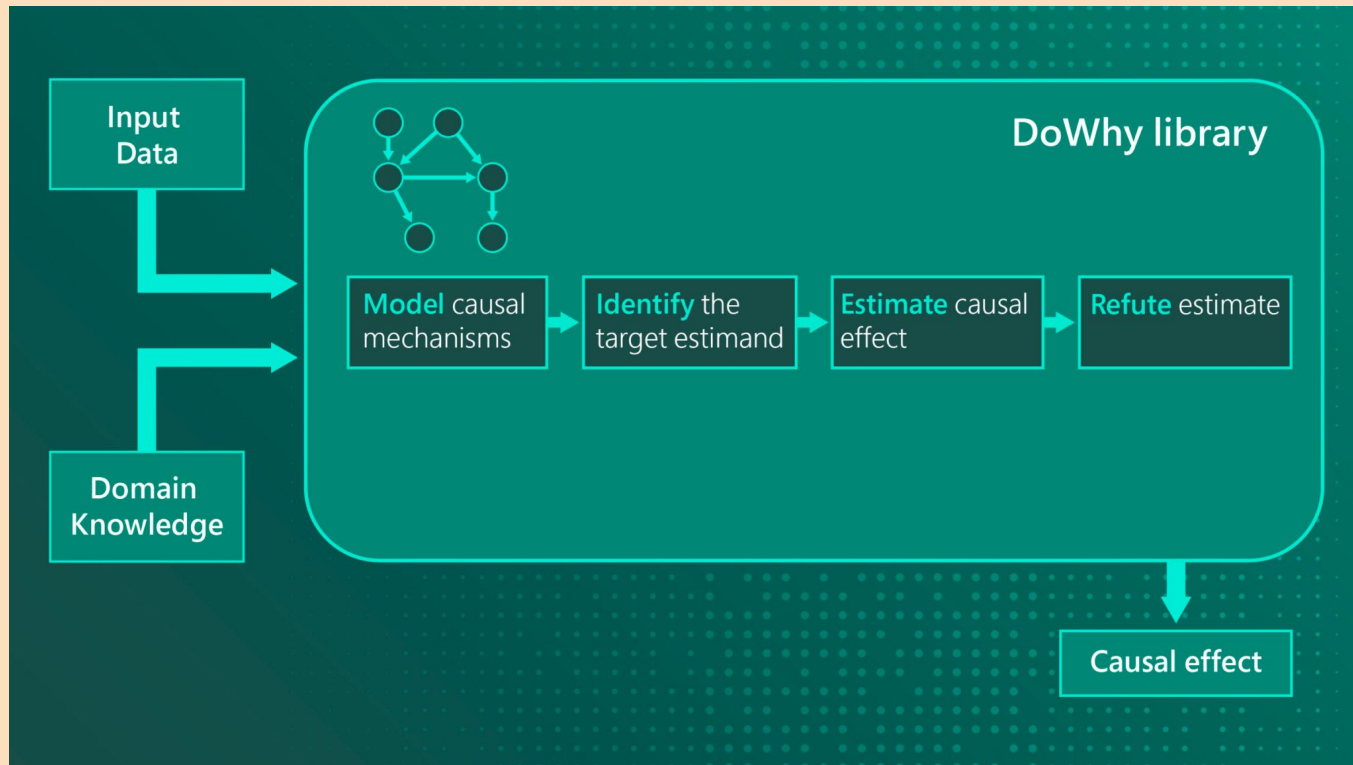
INFERENCIA CAUSAL



OBJETIVOS

- Utilizar **DoWhy** para estimar el efecto causal de nuestro set de datos.
- **Modelar** relaciones causales entre los atributos de la cerveza para comprender las preferencias de los usuarios.
- Realizar pruebas de placebo para **refutar** estimaciones iniciales y validar conclusiones causales.
- **Analizar** la correlación de los atributos de la cerveza (IA explicable)

DOWHY



GENERACIÓN DE DATOS SINTÉTICOS

	color	cuerpo	malta	IBU	ABV	maridaje	cerveza	treatment
0	0	2	3	1	1	3	4	True
1	0	2	3	1	1	5	4	True
2	0	2	3	1	1	1	4	True
3	0	2	3	1	1	0	4	True
4	0	2	3	1	1	2	4	True
...
11995	1	1	2	5	5	5	7	False
11996	1	1	2	5	5	1	7	True
11997	1	1	2	5	5	0	5	True
11998	1	1	2	5	5	2	5	True
11999	1	1	2	5	5	4	7	True

12000 rows x 8 columns

True	9066
False	2934

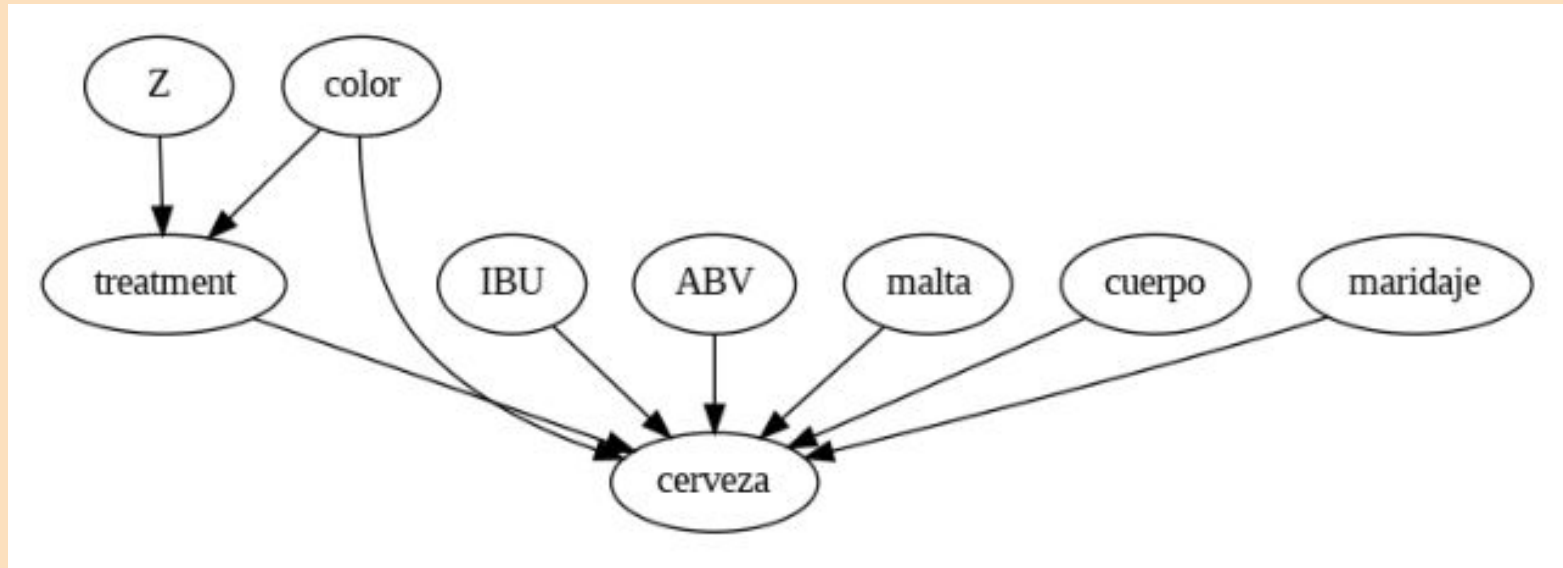
MODELADO CAUSAL

Probamos varios modelos causales:

- 1) Utilizando cada atributo (color, cuerpo, malta, IBU, ABV, y maridaje) como una variable de tratamiento.
- 2) Excluyendo cada atributo a la vez para observar los cambios en la influencia de las otras características.

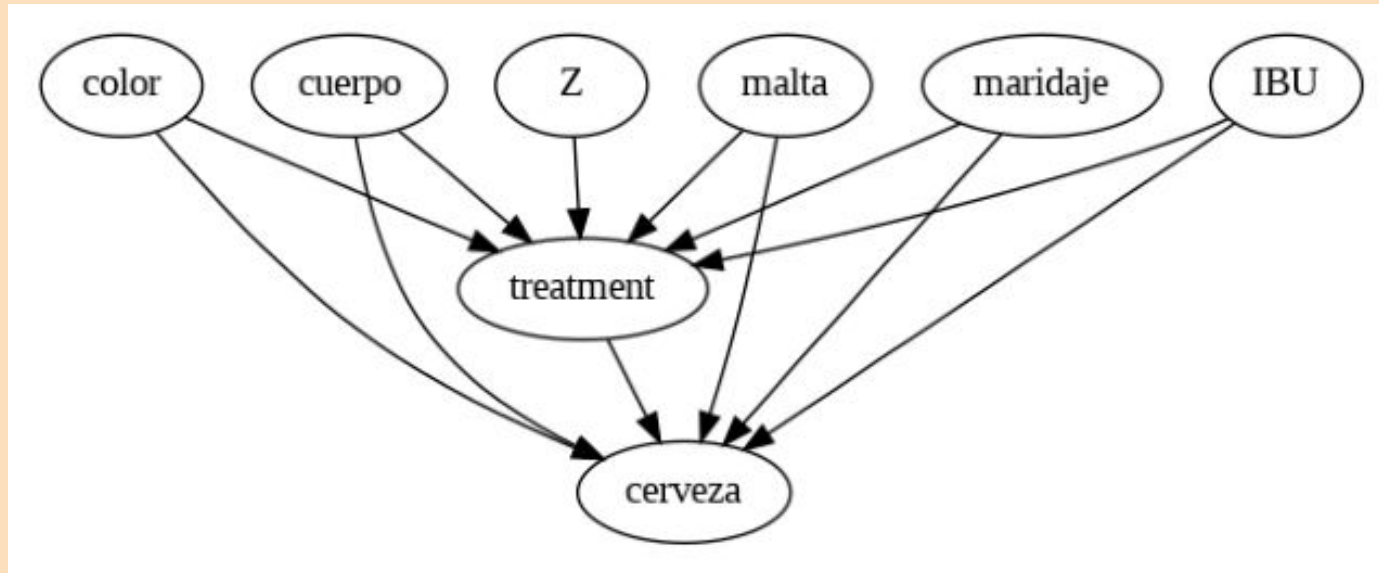
MODELADO CAUSAL

Por ejemplo 1)



MODELADO CAUSAL

Por ejemplo 2)



ESTIMACIÓN DE EFECTOS CAUSALES

Resultados: en todos los casos, el efecto estimado cambió significativamente tras aplicar una refutación

Conclusión: nuestros atributos de cerveza en las recomendaciones podrían no ser causales.

```
Refute: Use a Placebo Treatment  
Estimated effect:-1.342598720494154  
New effect:0.004378998455768803  
p value:0.47952148524809185
```

REFUTACIÓN DE ESTIMACIONES

Resultados: P values mayores a 0.21 en todos los casos

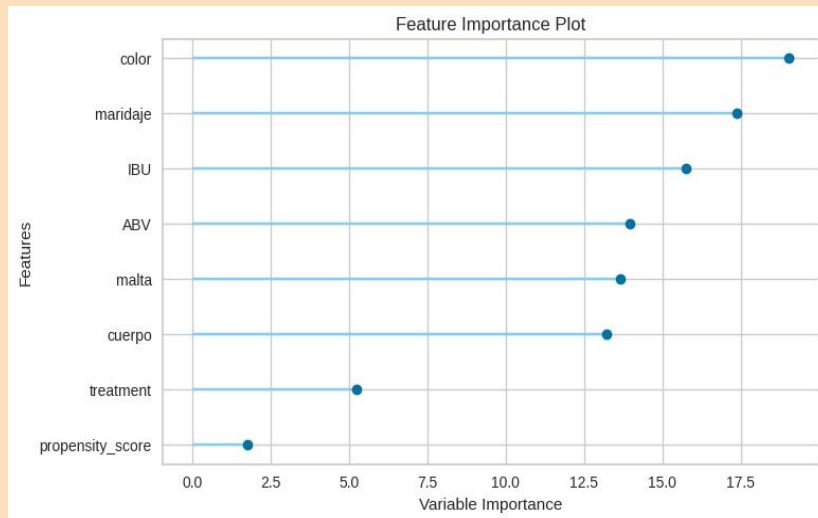
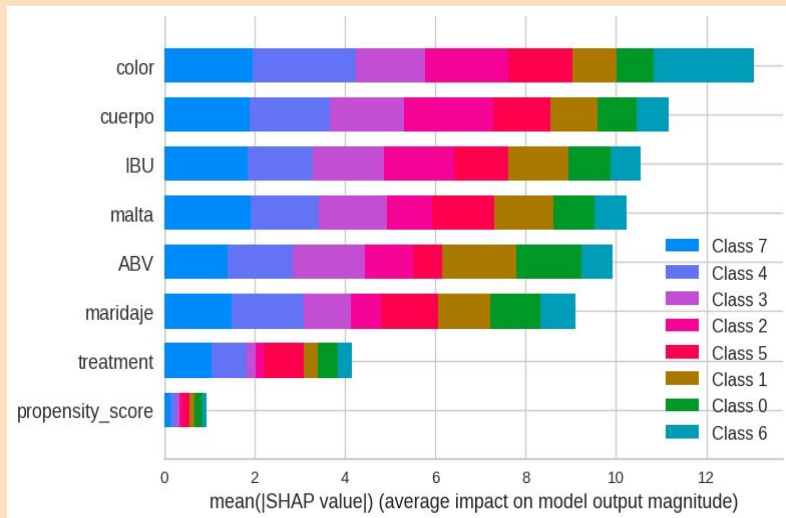
Conclusión:

- Ningún atributo, considerado individualmente, tiene un impacto significativo
- Podrían existir otros factores no capturados en el modelo

```
Refute: Use a Placebo Treatment
Estimated effect:-1.342598720494154
New effect:0.004378998455768803
p value:0.47952148524809185
```


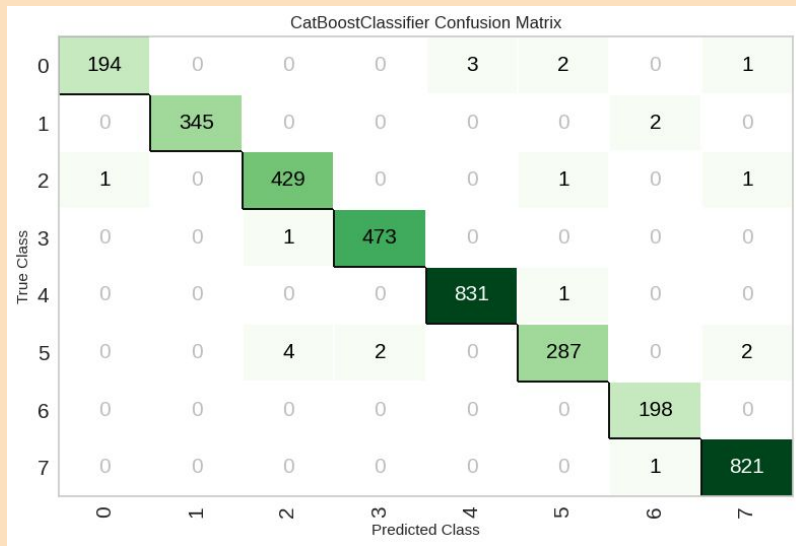
ANÁLISIS DE FACTORES CON IA

La relevancia de cada una de las características es la esperada




ANÁLISIS DE FACTORES CON IA

Rendimiento del modelo extremadamente alto: overfitting



04


CONCLUSIONES



CONCLUSIONES

- Características de cerveza sin impacto causal claro.
- P values elevados que refutan causalidad directa.
- Modelo actual requiere refinamiento y más datos.
- Posiblemente existan factores adicionales influyentes.

GRACIAS!



PREGUNTAS?